RAPPORT DE FIN DE STAGE

Présenté par :

Mlle KIENOU Gwladys Carmène

Sujet

Prédire le chiffre d'affaire de Telecel

Sous la direction de :

M. Salam OUEDRAOGO **: Encadrant Entreprise**

Rapport de fin de stage soutenu le 29 Septembre 2025, devant le jury composé de:

M. Marcial KIBA : **Chef de service**

Année Universitaire : 2024 -2025

Rapport de Stage : Analyse et Prédiction du Chiffre d'Affaire de Telecel

1. Introduction

Le stage a pour objectif de réaliser une analyse complète des données de transactions de Telecel, afin de comprendre les comportements des utilisateurs et la répartition des revenus.

Ce travail comprend :

- La compréhension et l'exploration des données.
- Le nettoyage et la préparation des données.
- L'analyse univariée et bivariée, multivariée pour identifier les tendances.
- La mise en place de bases pour de futurs modèles de prédiction.

2. Importation des bibliothèques et chargement des données

```python
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline

# Chargement des données
df = pd.read_excel("Telecel_revenue.xlsx")
df.head()
```

La base de donnée contient initialement **272989 lignes et 14 colonnes**.

Les colonnes décrivent les transactions par type (DATA, VOIX, SMS, FORFAITS, VAS) avec des informations sur la durée, le volume et les montants.

3. Compréhension et exploration initiale

- Types de colonnes et statistiques descriptives :

```python
df.info()
df.describe(include="all")
```

- **Aperçu des données :** `df.sample(10)`
- Les valeurs atypiques et les distributions sont visibles dès l'inspection initiale.

4. Nettoyage des données

4.1. Détection des valeurs manquantes

```python
df.isnull().sum()
total_missing = df.isnull().sum().sum()
print("Le nombre total de valeurs manquantes est de :", total_missing)
```

- Total des valeurs manquantes : **361468**
- Colonnes fortement affectées : UpFlux, DownFlux, OCTETS, forfait_TEMPS, forfait_DUREE, forfait_OCTETS.

4.2. Suppression et correction

```python
df.dropna(inplace=True)
df.drop_duplicates(inplace=True)
df.fillna(0, inplace=True)
df.columns = df.columns.str.strip().str.lower().str.replace(" ", "_")
```

- Après nettoyage, **la base contient 159754 lignes et 14 colonnes**.
- Toutes les colonnes vides et doublons ont été supprimés.

5. Analyse exploratoire des données (EDA)

5.1. Analyse univariée

❖ Distribution du chiffre d'affaire (amountprincipal)

```python
plt.figure(figsize=(8,5))
sns.histplot(df_eda['amountprincipal'], bins=50, kde=True)
plt.title("Distribution du chiffre d'affaire")
plt.show()
```

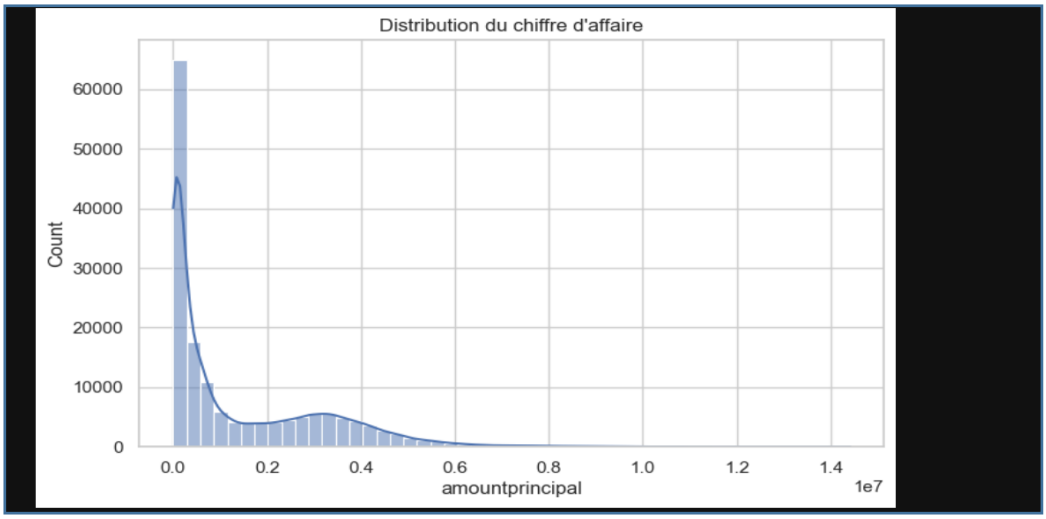

Remarque : La majorité des transactions sont sur de petits montants, avec quelques valeurs très élevées.

❖ Distribution des bonus (amountbonus)

```python
plt.figure(figsize=(8,5))
sns.histplot(df_eda['amountbonus'], bins=50, kde=True, color="green")
plt.title("Distribution des bonus")
plt.show()
```

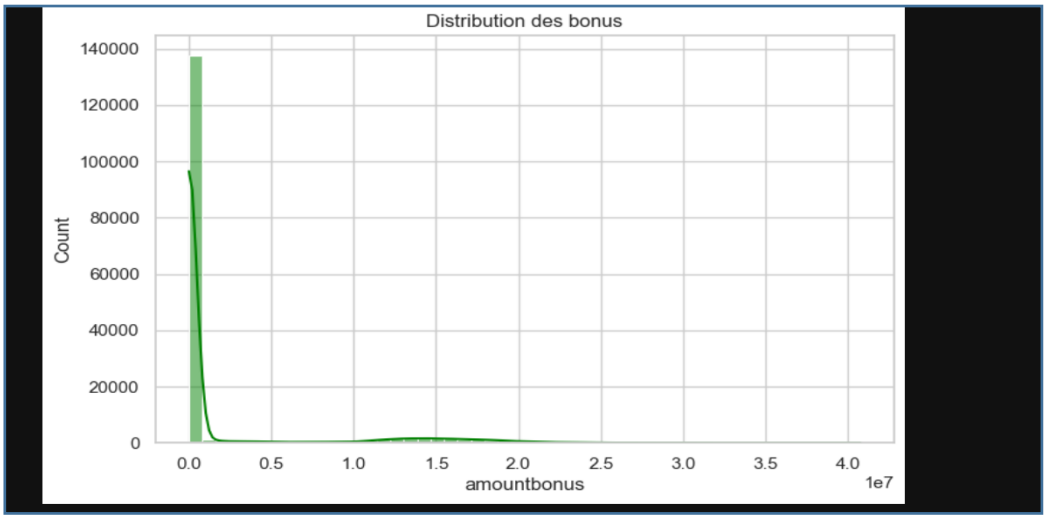

Remarque : Même tendance que le chiffre d'affaires : la majorité des bonus sont faibles.

❖ Répartition par catégorie

```
plt.figure(figsize=(8,5))
sns.countplot(x="categorie", data=df_eda, order=df_eda["categorie"].value_counts().index, palette=
plt.title("Répartition des transactions par catégorie")
plt.xticks(rotation=45)
plt.show()
```

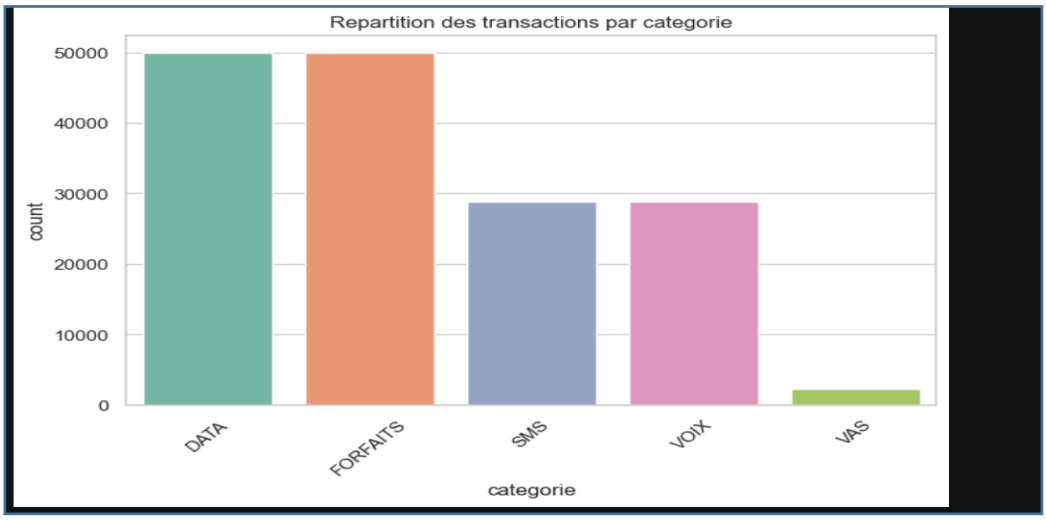

Remarque : Les catégories DATA et FORFAITS dominent largement les transactions.

5.2. Analyse bivariée

❖ Chiffre d'affaire moyen par catégorie

```python
plt.figure(figsize=(10,6))
sns.barplot(x="categorie", y="amountprincipal", data=df_eda, estimator="mean")
plt.title("Chiffre d'affaire moyen par catégorie")
plt.xticks(rotation=45)
plt.show()
```

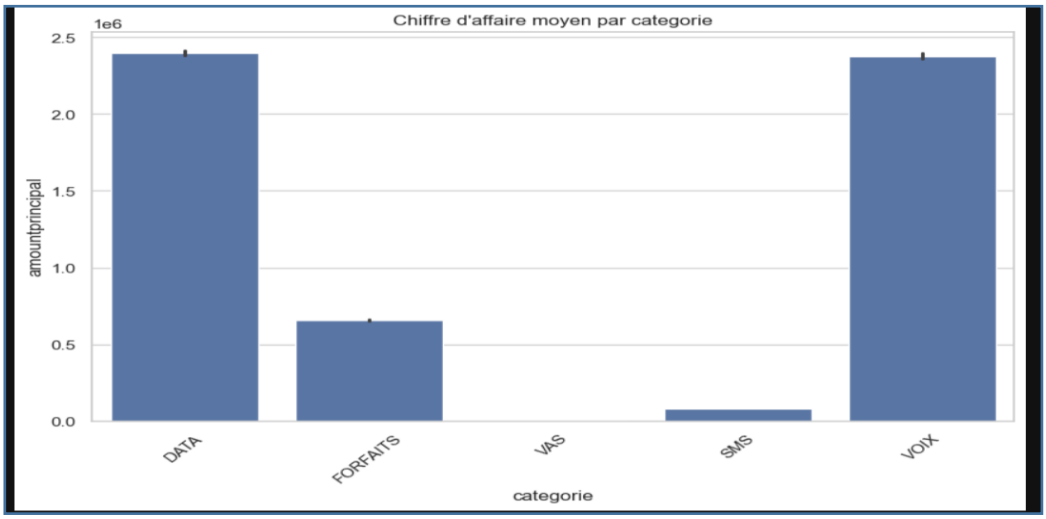

Remarque : Certaines catégories génèrent plus de revenus que d'autres.

❖ Relation entre bonus et chiffre d'affaire

```python
plt.figure(figsize=(8,6))
sns.scatterplot(x="amountbonus", y="amountprincipal", data=df_eda, alpha=0.5)
plt.title("Relation entre bonus et chiffre d'affaire")
plt.show()
```

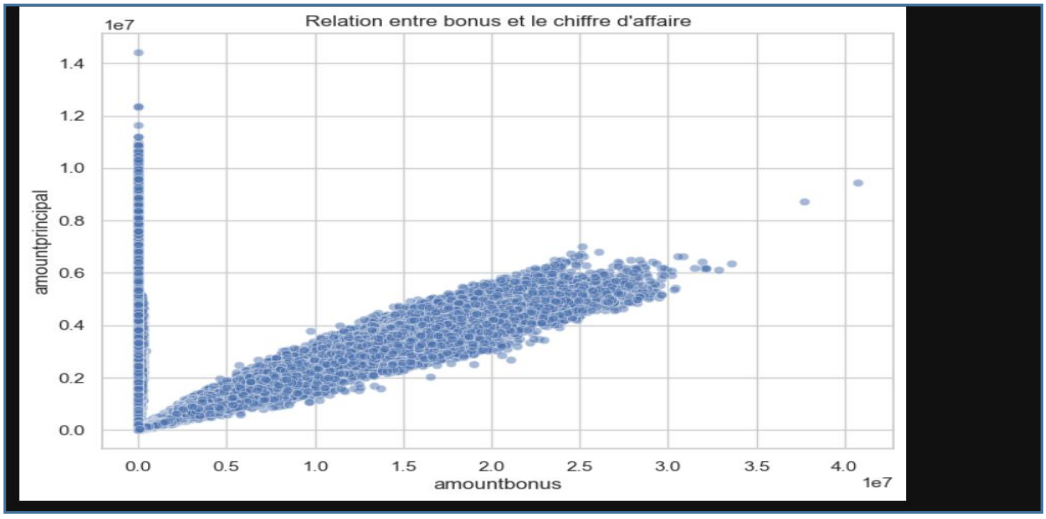

Remarque : Corrélation positive : plus le bonus est élevé, plus le chiffre d'affaire est important.

5.3. Analyse multivariée

❖ Matrice de corrélation

La matrice de corrélation permet d'identifier les relations entre les variables numériques et de déterminer celles qui seront les plus pertinentes pour un futur modèle prédictif. Le code utilisé pour générer cette matrice est :

```python
plt.figure(figsize=(12,7))
sns.heatmap(df_eda.corr(numeric_only=True), annot=True, cmap="coolwarm", fmt=".2f")
plt.title("Matrice de correlation")
plt.show()
```

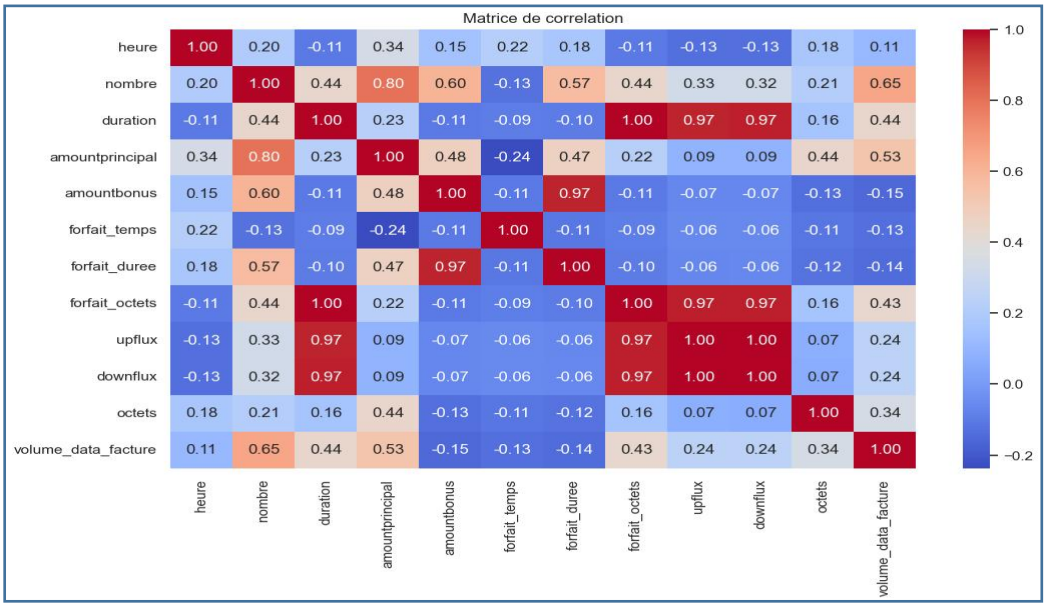

Remarque : L'analyse de la matrice montre que le **chiffre d'affaires principal** (amountprincipal) est fortement corrélé avec les **bonus** (amountbonus) et la **durée** (duration) des services, tandis que la corrélation avec les **octets** (octets) est relativement faible. Cette information est cruciale pour orienter la sélection des variables lors de la construction de modèles prédictifs.

- ❖ Pairplot sur un échantillon

Un pairplot a été réalisé sur un échantillon de 1000 observations pour visualiser les interactions entre plusieurs variables clés et observer l'impact de la catégorie sur ces relations.

```python
sns.pairplot(df_eda.sample(1000), vars=["amountprincipal","amountbonus","duration",
plt.show()
```

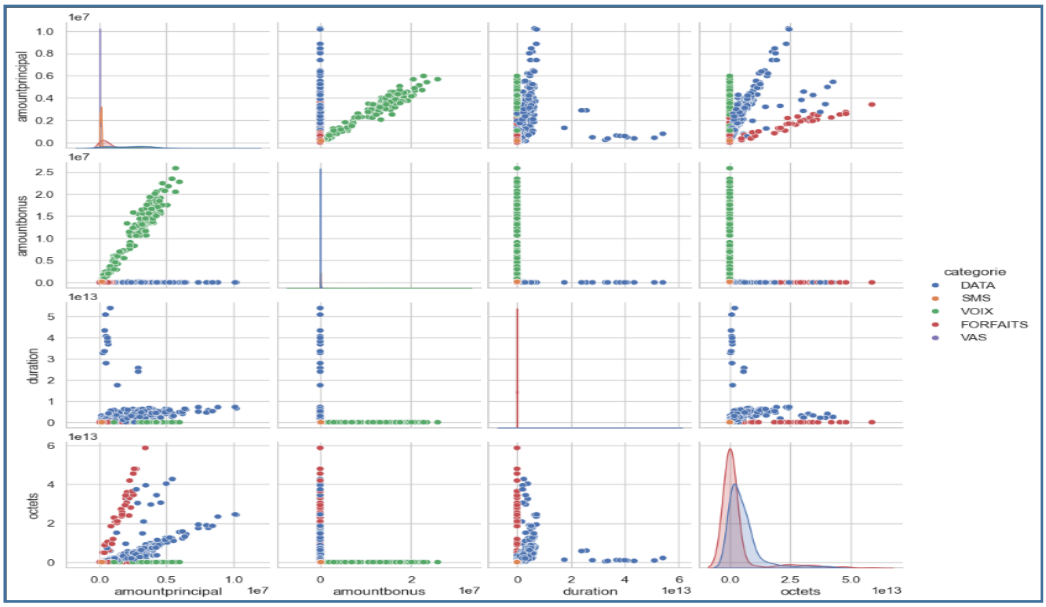

Remarque : Les relations entre les variables diffèrent selon la catégorie. Certaines tendances sont visibles, indiquant que la **catégorie** joue un rôle structurant dans la génération du chiffre d'affaires.

❖ Chiffre d'affaires par type d'usage

Pour hiérarchiser les sources de revenus et guider les décisions stratégiques, le chiffre d'affaires a été agrégé par catégorie **:**

```python
df_eda_ca_cat = df_eda.groupby("categorie")["amountprincipal"].sum().reset_index().
plt.figure(figsize=(10,6))
sns.barplot(x="categorie", y="amountprincipal", data=df_eda_ca_cat)
plt.title("Chiffre d'affaire total par categorie (Data, SMS, Voix, Forfaits, VAS)")
plt.xticks(rotation=45)
plt.show()
```

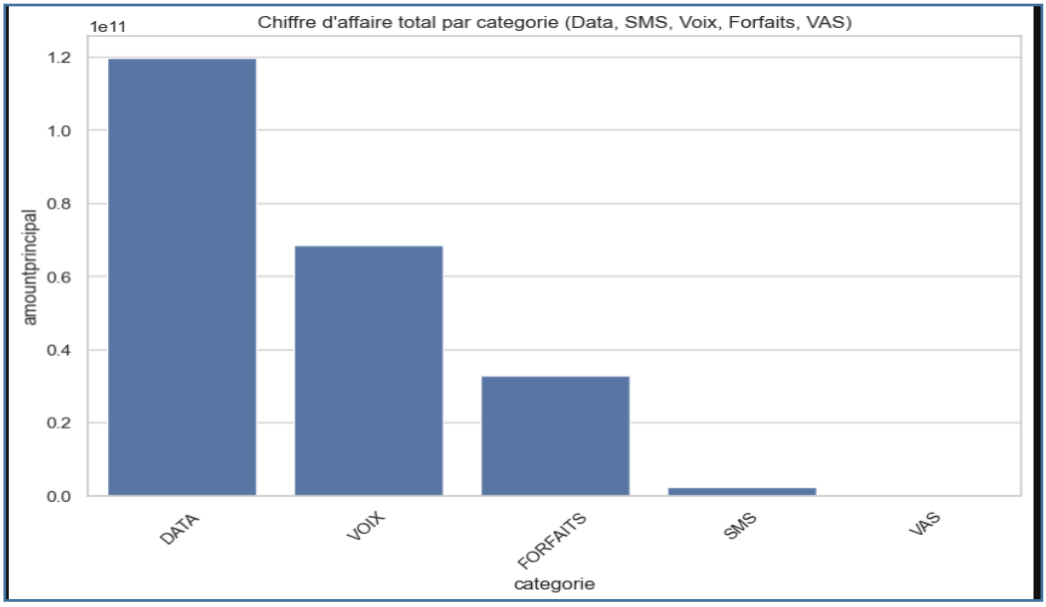

Remarque : Deux catégories, DATA et VOIX, génèrent la majorité du chiffre d'affaires, ce qui indique leur importance stratégique pour l'entreprise.

❖ Évolution du chiffre d'affaires par catégorie dans le temps

```python
df_eda_time = df_eda.groupby(["datej","categorie"])["amountprincipal"].sum().reset_
plt.figure(figsize=(14,7))
sns.lineplot(x="datej", y="amountprincipal", hue="categorie", data=df_eda_time)
plt.title("Evolution du chiffre d'affaires par categorie dans le temps")
plt.show()
```

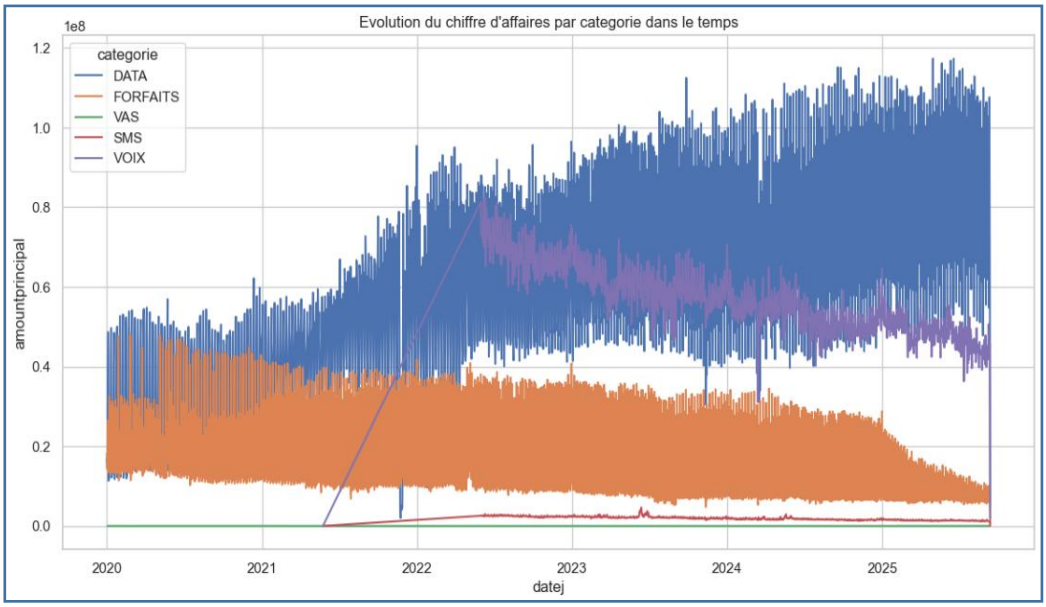

Remarque : Des tendances saisonnières sont observables, avec certaines catégories qui connaissent une croissance plus rapide que d'autres. Cette analyse temporelle est essentielle pour la planification commerciale et la prévision des revenus.

Conclusion Générale

L'analyse exploratoire des données révèle que :

- Les variables **bonus** et **durée** sont fortement corrélées au chiffre d'affaires et sont donc cruciales pour la prédiction.
- La **catégorie de service** influence fortement les relations entre variables et la génération de revenus.
- Les catégories **DATA** et **VOIX** sont les principales sources de chiffre d'affaires.
- L'évolution temporelle du chiffre d'affaires montre des **tendances saisonnières**, ce qui permettra d'anticiper et d'optimiser les stratégies commerciales.

6. Prévisions du chiffre d'affaires avec Prophet

Pour anticiper l'évolution future du chiffre d'affaires, nous avons utilisé la bibliothèque **Prophet**, développée par Facebook. Prophet est spécialement conçu pour la prévision de séries temporelles, même avec des données comportant des tendances saisonnières, des vacances ou des fluctuations irrégulières. Il est particulièrement adapté aux données commerciales comme le chiffre d'affaires quotidien ou mensuel.

6.1. Préparation des données

Avant d'utiliser Prophet, les données ont été préparées et renommées selon le format attendu :

- **ds** : date (variable temporelle)
- **y** : valeur à prédire (ici, le chiffre d'affaires principal)

```python
df_eda_prophet = df_eda_ca.rename(columns={"datej": "ds", "amountprincipal": "y"})
```

6.2. Initialisation et entraînement du modèle

Le modèle Prophet est initialisé avec une saisonnalité annuelle et sans saisonnalité journalière, puis entraîné sur les données historiques.

```python
model = Prophet(yearly_seasonality=True, daily_seasonality=False)
model.fit(df_eda_prophet)
```

Le log indique que le modèle a bien fini le traitement des chaînes de Markov :

```bash
09:02:41 - cmdstanpy - INFO - Chain [1] done processing
```

6.3. Prévision sur 3 ans

On crée un DataFrame pour générer des prédictions sur **36 mois** (3 ans) supplémentaires.

```python
future = model.make_future_dataframe(periods=36, freq="ME")
forecast = model.predict(future)
```

6.4. Visualisation des prévisions

- Courbe principale

```python
fig1 = model.plot(forecast)
plt.title("Prévision du chiffre d'affaires pour 3 ans")
plt.xlabel("Date")
plt.ylabel("Chiffre d'affaires")
plt.show()
```

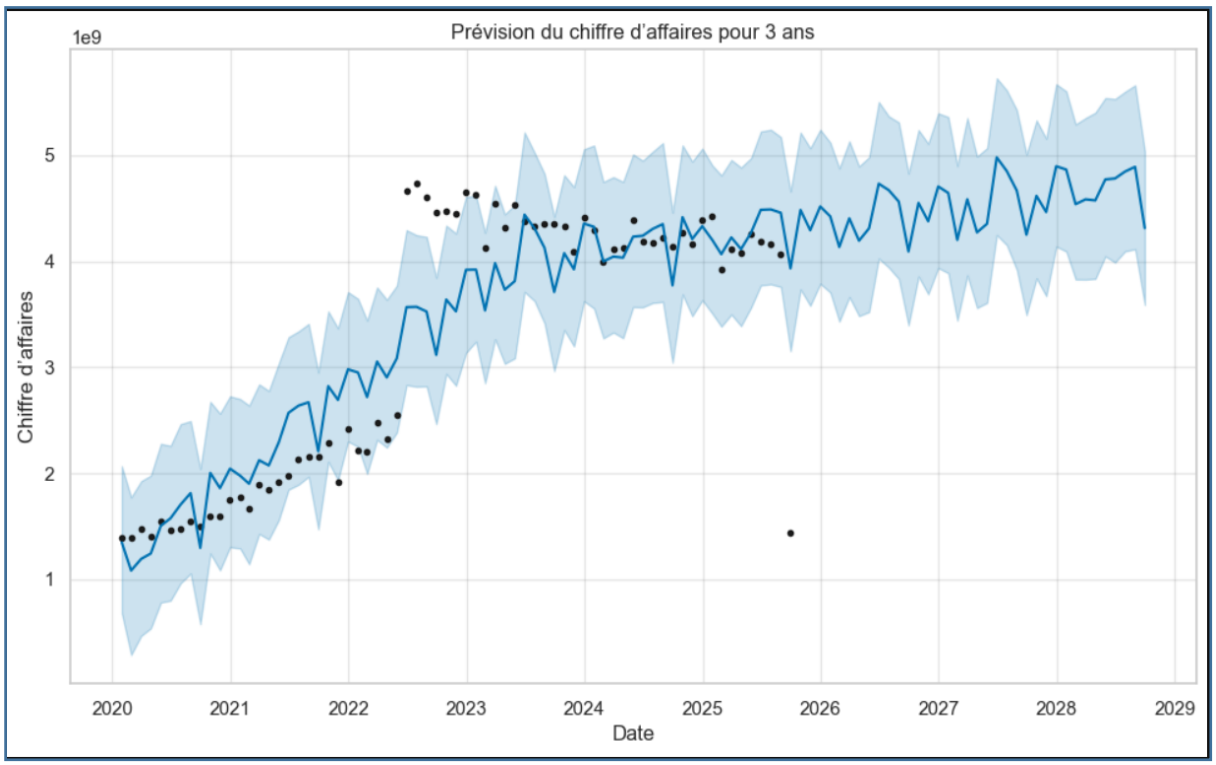

Interprétation :

- La courbe **yhat** montre l'évolution prévue du chiffre d'affaires.
- Les bandes **yhat_lower et yhat_upper** représentent l'**intervalle d'incertitude**. Plus elles sont larges, plus la prévision est incertaine.
- Cette visualisation permet d'anticiper l'activité sur 3 ans.

Décomposition : tendance et saisonnalité

```python
fig2 = model.plot_components(forecast)
plt.show()
```

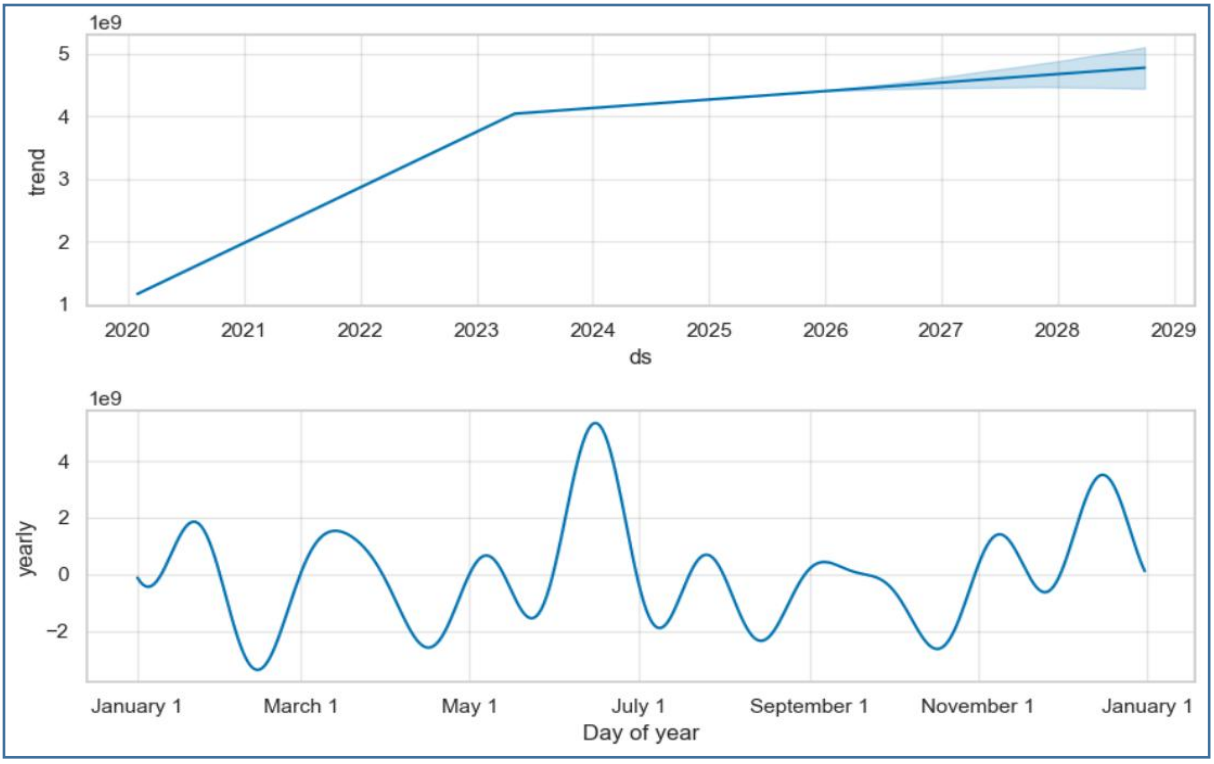

Interprétation :

- **Tendance (trend)** : montre la direction à long terme du chiffre d'affaires (hausse, baisse, stagnation).
- **Saisonnalité (yearly)** : indique les périodes de l'année où le chiffre d'affaires a tendance à augmenter ou diminuer.

Aperçu des prévisions futures

On peut examiner les 12 derniers mois de prévision pour observer l'évolution attendue :

- **yhat :** prévision ponctuelle (moyenne)
- **yhat_lower / yhat_upper** : intervalle d'incertitude à 80 %

- On peut observer la tendance et la volatilité prévue sur les prochains mois. Une bande large indique plus d'incertitude.

Prévision du chiffre d'affaires pour 3 ans

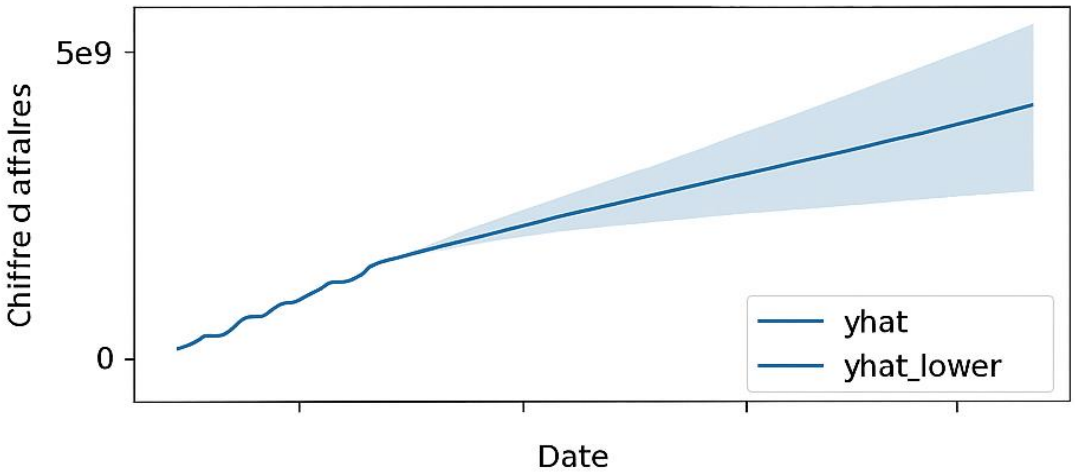

Décomposition : tendance + saisonnalité

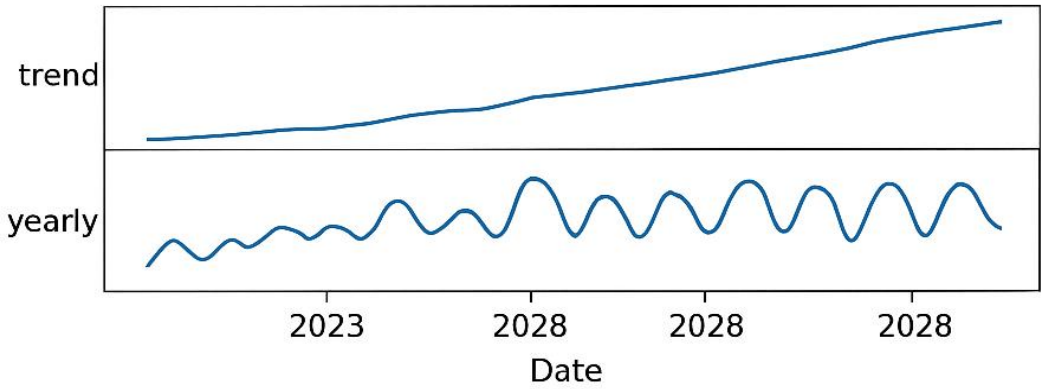

Aperçu des prévisions futures

	yhat	yhat_lower	yhat_upper
2027-10-31	4.616e+09	3.838e-99	5.329e+09
2027-11-30	4.464e+09	3.670s-09	5.158e+09
2027-12-31	4.538e+09	4.138e-63	5.6710529
2028-09-30	4.5830479	4.8321-28	5.2922234
2028-05-30	4.5737949	8.3832-98	5.6038605
2028-09-30	4.4610+09	3.8272-90	5.6930709

7. Conclusion Générale

Ce stage a permis d'analyser en profondeur le chiffre d'affaires à travers des **explorations de données**, des visualisations et des **prévisions avec Prophet**. L'étude a montré que les variables **bonus**, **durée** et la **catégorie de service** influencent fortement les revenus, avec **DATA** et **VOIX** comme principales sources.

L'évolution temporelle a révélé des **tendances saisonnières**, et les prévisions avec Prophet offrent une **vision fiable des revenus futurs**, utile pour la planification stratégique et la prise de décision.

En résumé, ce travail a renforcé mes compétences en **analyse de données et prévision**, tout en apportant à l'entreprise des outils concrets pour optimiser sa stratégie commerciale.